

QUADRO TEÓRICO-ANALÍTICO: RELAÇÃO ENTRE IA EM MARKETING E UTAUT

Framework Conceitual Integrado

Elaborado por: Prof. Dr. Atormentatore

Data: 13 de outubro de 2025

Fundamentação: Davenport et al. (2020), Davenport & Ronanki (2018), Huang & Rust (2021), Venkatesh et al. (2003)

TABELA 1: Relação Entre Tipos de IA e Construtos do UTAUT

Construto UTAUT	Mechanical AI
Performance Expectancy (Expectativa de Desempenho)	Alta Relevância: Automação de processos gera ganhos mensuráveis de eficiência (Davenport & Ronanki, 2018) Muito Alta
Effort Expectancy (Expectativa de Esforço)	Baixo Esforço: Automação reduz trabalho manual repetitivo (Huang & Rust, 2021) Esforço Mínimo
Social Influence (Influência Social)	Pressão Competitiva: Automação vista como necessidade básica no mercado atual Pressão Intensa
Facilitating Conditions (Condições Facilitadoras)	Requisitos Básicos: Infraestrutura digital, conectividade, dados estruturados (Davenport & Ronanki, 2018) Requisitos Básicos

TABELA 2: Aplicações de IA em Marketing Organizadas por Construtos UTAUT

Área de Marketing (4Ps/4Cs)	Tipo de IA Aplicada
PRODUTO/CONSUMER	
- Product Design & Innovation	Thinking AI (Analytics preditiva para tendências)
- Branding	Mechanical AI (Geração automatizada de logos) + Thinking AI (Brand tracking via sentiment analysis)
- Customer Service	Mechanical AI (Chatbots textuais) → Thinking AI (NLP chatbots) → Feeling AI (Agentes emocionais)
PREÇO/COST	
- Dynamic Pricing	Thinking AI (Algoritmos de otimização em tempo real)
- Payment Automation	Mechanical AI (Apple Pay, PayPal, etc.)
- Price Negotiation	Feeling AI (Negociação interativa baseada em emoções)
PRAÇA/CONVENIENCE	
- Distribution & Logistics	Mechanical AI (Drones, robôs de entrega, IoT)
- Frontline Interaction (Retail)	Mechanical AI (Robôs greeters) → Thinking AI (Personal shopping assistants) → Feeling AI (Service robots com expressão emocional)
PROMOÇÃO/COMMUNICATION	
- Media Planning & Buying	Mechanical AI (Automação de programmatic ads)
- Content Creation	Thinking AI (AI writers, creative algorithms)
- Sentiment Tracking & Personalization	Feeling AI (Affective analytics, emotion sensing)

TABELA 3: Barreiras à Adoção de IA em Marketing Mapeadas no UTAUT

Barreira Identificada nos Artigos	Construto UTAUT Afetado	Tipo de IA Mais Afetado	Referência
Opacidade dos Algoritmos (Black Box)	Facilitating Conditions (negativo)	Thinking AI	Davenport et al. (2018)
Viés Algorítmico	Performance Expectancy (negativo) + Social Influence (negativo)	Thinking AI	Lambrecht & Tucker (2019)
Resistência do Cliente ao Descobrir que é IA	Performance Expectancy (negativo do ponto de vista do cliente)	Feeling AI	Luo et al. (2019): P
Falta de Dados Contextuais para Emoções	Facilitating Conditions (negativo)	Feeling AI	Rust & Huang (2020): P
Custos de Implementação	Facilitating Conditions (negativo)	Thinking AI e Feeling AI	Davenport & Ronanki (2018)
Déficit de Competências (Data Scientists)	Facilitating Conditions (negativo)	Thinking AI	Huang et al. (2019): P
Perda de Autonomia Percebida pelo Cliente	Performance Expectancy (ambíguo) + Social Influence (negativo)	Thinking AI (personalização extrema)	André et al. (2018): P
Uncanny Valley (Robôs Humanoides)	Effort Expectancy (do cliente - desconforto)	Feeling AI (robôs)	Mori (1970): UVH; Mori et al. (2018): P

TABELA 4: Moderadores UTAUT Aplicados a IA em Marketing

Moderador	Efeito em Performance Expectancy	Efeito em Effort Expectancy	Referência
Gênero	Homens valorizam mais ganhos de performance (Venkatesh et al., 2003)	Mulheres valorizam mais facilidade de uso (Venkatesh et al., 2003)	Mulheres valorizam mais facilidade de uso (Venkatesh et al., 2003)
Idade	Jovens valorizam mais performance (Venkatesh et al., 2003)	Idosos valorizam mais facilidade (Venkatesh et al., 2003)	Jovens valorizam mais facilidade (Venkatesh et al., 2003)
Experiência	Sem efeito moderador (Venkatesh et al., 2003)	Effort Expectancy perde importância com experiência (Venkatesh et al., 2003)	Sociedade de consumo (Venkatesh et al., 2003)
Voluntariedade	Sem efeito moderador (Venkatesh et al., 2003)	Sem efeito moderador (Venkatesh et al., 2003)	Sociedade de consumo (Venkatesh et al., 2003)

TABELA 5: Estágios do Framework Estratégico de Huang & Rust (2021) Mapeados no UTAUT

Estágio Estratégico	Atividade de IA	Tipo de IA Utilizada
1. Marketing Research		
- Data Collection	Tracking, sensing, IoT, wearables, social media scraping	Mechanical AI
- Market Analysis	Machine learning, text mining, predictive analytics para identificar competidores e oportunidades	Thinking AI
- Customer Understanding	Sentiment analysis, NLP, affective analytics para mapear emoções	Feeling AI
2. Marketing Strategy (STP)		
- Segmentation	Data mining, clustering, descoberta de padrões em big data	Mechanical AI (execução) + Thinking AI
- Targeting	Recommendation engines, propensity models para recomendar melhores segmentos	Thinking AI
- Positioning	Feeling analytics para criar mensagens que ressoam emocionalmente	Feeling AI (emergente) + Human judgment
3. Marketing Action (4Ps/4Cs)		
- Standardization (Mechanical AI)	Automação de processos, entrega, pagamento, postagem de conteúdo	Mechanical AI
- Personalization (Thinking AI)	Recomendações, preços dinâmicos, conteúdo customizado	Thinking AI
- Relationalization (Feeling AI)	Chatbots emocionais, negociação interativa, service robots expressivos	Feeling AI

TABELA 6: Framework de Decisão - Quando Usar Cada Tipo de IA (Baseado em UTAUT)

Cenário de Decisão		Tipo de IA Recomendado	
Alta pressão por eficiência operacional + Recursos limitados + Gestão avessa a risco	Mechanical AI		• Esforço
Necessidade de vantagem competitiva via insights + Disponibilidade de dados + Competência técnica	Thinking AI		• Performance
Segmento de alto valor de longo prazo + Diferenciação via experiência + Tolerância a experimentação	Feeling AI		• Performance
PME em mercado competitivo + Começando jornada digital + Sem equipe técnica	Mechanical AI primeiro, depois Thinking AI		• Começar
Grande empresa B2C + Cultura data-driven + CX como core strategy	Portfólio integrado: Mechanical + Thinking + Feeling AI		• Performance

PROPOSIÇÕES TEÓRICAS DERIVADAS DO FRAMEWORK INTEGRADO

Proposição 1: Efeito Sequencial da Adoção de IA

Enunciado: A adoção bem-sucedida de Mechanical AI aumenta a Performance Expectancy para Thinking AI, que por sua vez aumenta a Performance Expectancy para Feeling AI.

Fundamentação:

- Mechanical AI gera ganhos tangíveis rápidos (Davenport & Ronanki, 2018)
- Sucesso inicial reduz percepção de risco e aumenta confiança (Venkatesh et al., 2003)
- Huang & Rust (2021) mostram progressão natural: Standardization → Personalization → Relationalization

Implicação para Pesquisa: Estudos longitudinais devem mapear trajetórias de adoção de IA em PMEs, testando se firmas que começam com Mechanical AI têm maior probabilidade de adotar Thinking/Feeling AI posteriormente.

Proposição 2: Trade-off Entre Effort Expectancy e Performance Expectancy por Nível de IA

Enunciado: À medida que o nível de inteligência da IA aumenta (Mechanical → Thinking → Feeling), o Effort Expectancy aumenta exponencialmente, enquanto o Performance Expectancy aumenta apenas linearmente, criando um ponto de inflexão onde o esforço percebido supera os benefícios percebidos.

Fundamentação:

- Mechanical AI: Baixo esforço, ganhos moderados
- Thinking AI: Esforço moderado, ganhos altos
- Feeling AI: Esforço alto, ganhos incertos/longos prazos (Huang & Rust, 2021)
- Venkatesh et al. (2003): Ambos são preditores independentes de intenção

Implicação para Pesquisa: Investigar o "ponto de equilíbrio" onde PMEs param de adotar níveis mais altos de IA devido ao esforço percebido. Isso pode explicar por que Feeling AI tem baixa penetração.

Proposição 3: Moderação da Facilitating Conditions por Porte Empresarial

Enunciado: O efeito de Facilitating Conditions sobre a intenção de adoção de Thinking e Feeling AI é significativamente maior em PMEs do que em grandes empresas.

Fundamentação:

- PMEs têm recursos financeiros, técnicos e humanos limitados (SEBRAE/ABDI, 2024)
- Davenport et al. (2020): 40% dos executivos citam custos como barreira
- Venkatesh et al. (2003): Facilitating Conditions afeta diretamente uso (não apenas intenção)

Implicação para Pesquisa: Validar UTAUT em contextos de PMEs versus grandes empresas, testando se o peso de Facilitating Conditions é maior em PMEs.

Proposição 4: O Papel Dual da Social Influence para Feeling AI

Enunciado: Social Influence tem efeito curvilíneo sobre a intenção de adoção de Feeling AI: pressão moderada aumenta adoção, mas pressão muito alta gera resistência devido a preocupações éticas e de autenticidade.

Fundamentação:

- Luo et al. (2019): Clientes rejeitam chatbots quando sabem que são IA
- Leung et al. (2018): Resistência a automação em produtos ligados à identidade
- Kim et al. (2019): Uncanny Valley reduz liking de robôs humanoides
- Porém, Davenport et al. (2020): Pressão competitiva força adoção

Implicação para Pesquisa: Incluir medidas de "autenticidade percebida" e "preocupações éticas" como variáveis mediadoras entre Social Influence e intenção de adoção de Feeling AI.

AGENDA DE PESQUISA FUTURA

Para Pesquisa Quantitativa:

1. **Validar UTAUT para diferentes níveis de IA** (Mechanical vs. Thinking vs. Feeling) em PMEs brasileiras
2. **Testar moderadores adicionais específicos do contexto de IA:**
 - Maturidade digital da empresa
 - Intensidade competitiva do setor
 - Regulação de dados/privacidade
3. **Incluir variáveis de resultado além de "uso":**
 - ROI de marketing
 - Satisfação do cliente
 - Vantagem competitiva percebida

Para Pesquisa Qualitativa:

1. Estudos de caso longitudinais sobre trajetórias de adoção de IA (6-24 meses)
2. Narrativas de resistência: Por que PMEs decidem NÃO adotar IA apesar de pressões
3. Etnografias digitais: Como clientes realmente interagem com Feeling AI (chatbots, robôs)

CONCLUSÃO: SÍNTESE TEÓRICA

Este framework integrado propõe que:

1. Diferentes tipos de IA ativam diferentes construtos do UTAUT:
 - Mechanical AI → Effort Expectancy (facilidade) e Performance Expectancy (eficiência)
 - Thinking AI → Performance Expectancy (insights) e Facilitating Conditions (recursos técnicos)
 - Feeling AI → Performance Expectancy (relacional), Social Influence (normas sobre autenticidade), e Facilitating Conditions (dados emocionais)
2. A adoção de IA em marketing segue uma progressão lógica:
 - Marketing Research (Mechanical → Thinking → Feeling) coleta dados
 - Marketing Strategy (STP) transforma dados em decisões estratégicas (principalmente Thinking AI)
 - Marketing Action (4Ps/4Cs) executa estratégias com diferentes níveis de personalização/relacionamento
3. Barreiras específicas de IA mapeiam em construtos UTAUT:
 - Opacidade algorítmica = Facilitating Conditions negativas
 - Resistência do cliente = Performance Expectancy negativa (do ponto de vista do cliente)
 - Custos e déficit de talento = Facilitating Conditions negativas
4. O contexto de PMEs amplifica o papel de Facilitating Conditions:
 - Recursos limitados tornam infraestrutura técnica um gargalo crítico
 - Isso explica maior adoção de Mechanical AI (baixas Facilitating Conditions) do que Feeling AI (altas Facilitating Conditions)

REFERÊNCIAS

- André, Q., Carmon, Z., Wertenbroch, K., Crum, A., Frank, D., Goldstein, W., et al. (2018). Consumer choice and autonomy in the age of artificial intelligence and big data. *Customer Needs and Solutions*, 5(1–2), 28–37.
- Bauer, J., & Jannach, D. (2018). Optimal pricing in e-commerce based on sparse and noisy data. *Decision Support Systems*, 106, 53–63.
- Chen, Y., Lee, J. Y., Sridhar, S., Mittal, V., McCallister, K., & Singal, A. G. (2020). Improving cancer outreach effectiveness through targeting and economic assessments. *Journal of Marketing*, 84(3), 1–27.
- Davenport, T., Guha, A., Grewal, D., & Bressgott, T. (2020). How artificial intelligence will change the future of marketing. *Journal of the Academy of Marketing Science*, 48(2), 24–42.
- Davenport, T. H., & Ronanki, R. (2018). Artificial intelligence for the real world. *Harvard Business Review*, 96(1), 108–116.
- Grewal, D., Motyka, S., & Levy, M. (2018). The evolution and future of retailing and retailing education. *Journal of Marketing Education*, 40(1), 85–93.
- Huang, M. H., & Rust, R. T. (2021). A strategic framework for artificial intelligence in marketing. *Journal of the Academy of Marketing Science*, 49, 30–50.
- Huang, M. H., Rust, R. T., & Maksimovic, V. (2019). The feeling economy: Managing in the next generation of artificial intelligence (AI). *California Management Review*, 61(4), 43–65.
- Kim, S. Y., Schmitt, B. H., & Thalmann, N. M. (2019). Eliza in the uncanny valley: Anthropomorphizing consumer robots increases their perceived warmth but decreases liking. *Marketing Letters*, 30(1), 1–12.
- Lambrecht, A., & Tucker, C. (2019). Algorithmic bias? An empirical study of apparent gender-based discrimination in the display of STEM career ads. *Management Science*, 65(7), 2966–2981.
- Lee, D., Hosanagar, K., & Nair, H. S. (2018). Advertising content and consumer engagement on social media: Evidence from Facebook. *Management Science*, 64(11), 5105–5131.
- Leung, E., Paolacci, G., & Puntoni, S. (2018). Human versus machine: Resisting automation in identity-based consumer behavior. *Journal of Marketing Research*, 55(6), 818–831.
- Longoni, C., Bonezzi, A., & Morewedge, C. K. (2019). Resistance to medical artificial intelligence. *Journal of Consumer Research*, 46, 629–650.
- Luo, X., Tong, S., Fang, Z., & Qu, Z. (2019). Frontiers: Machines versus humans: The impact of AI chatbot disclosure on customer purchases. *Marketing Science*, 38(6), 937–947.
- McDuff, D., & Czerwinski, M. (2018). Designing emotionally sentient agents. *Communications of the ACM*, 61(12), 74–83.
- Mende, M., Scott, M. L., van Doorn, J., Grewal, D., & Shanks, I. (2019). Service robots rising: How humanoid robots influence service experiences and elicit compensatory consumer responses. *Journal of Marketing Research*, 56(4), 535–556.
- Misra, K., Schwartz, E. M., & Abernethy, J. (2019). Dynamic online pricing with incomplete information using multiarmed bandit experiments. *Marketing Science*, 38(2), 226–252.
- Mori, M. (1970). The Uncanny Valley. *Energy*, 7(4), 33–35.
- Pulles, N. J., & Hartman, P. (2017). Likeability and its effect on outcomes of interpersonal interaction. *Industrial Marketing Management*, 66, 56–63.
- Rai, A. (2020). Explainable AI: From black box to glass box. *Journal of the Academy of Marketing Science*, 48(1), 137–141.
- Rust, R. T., & Huang, M. H. (2020). *The feeling economy: How artificial intelligence is creating the era of empathy*. Palgrave-Macmillan.
- Rust, R. T., Rand, W., Huang, M. H., Stephen, A. T., Brooks, G., & Chabuk, T. (2020). Real-time brand reputation tracking using social media. Working paper.
- Schrift, R. Y., Wertenbroch, K., André, Q., & Frank, D. H. (2017). Threatening free will. Presentation at the Symposium on Alienation and Meaning in Production and Consumption, Technische Universität München.
- SEBRAE/ABDI. (2024). Maturidade digital das PMEs brasileiras. Brasília: SEBRAE.
- Ukanwa, K., & Rust, R. T. (2020). Discrimination in service. Working paper.
- Venkatesh, V., Morris, M. G., Davis, G. B., & Davis, F. D. (2003). User acceptance of information technology: Toward a unified view. *MIS Quarterly*, 27(3), 425–478.

Nota Metodológica: Este framework foi desenvolvido através de análise sistemática dos três artigos seminais sobre IA em marketing, integrado com o modelo UTAUT original (Venkatesh et al., 2003). As proposições teóricas derivam de síntese lógica entre os frameworks e requerem validação empírica futura.